



SVM的对偶算法

- 对于线性可分支持向量机的优化问题，原始问题：

$$\min_{w,b} \frac{1}{2} \|w\|^2$$

$$s.t. \quad y_i(w \cdot x_i + b) - 1 \geq 0, i = 1, 2, \dots, N$$

- 应用拉格朗日对偶性，通过求解对偶问题，得到原始问题的解。
- 优点：
 - 对偶问题往往容易解
 - 引入核函数，推广到非线性分类问题



SVM的对偶算法

- 定义拉格朗日函数

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i y_i (w \cdot x_i + b) + \sum_{i=1}^N \alpha_i$$

- 原问题：极小极大，对偶问题：极大极小

$$\min_{w,b} \theta_P(w, b) = \min_{w,b} \max_{\alpha: \alpha_i \geq 0} L(w, b, \alpha)$$



$$\max_{\alpha: \alpha_i \geq 0} \min_{w,b} L(w, b, \alpha)$$



学习的对偶算法

- 先求 $L(w, b, \alpha)$ 对 w, b 的极小，再求对 α 的极大

- 1、求： $\min_{w,b} L(w, b, \alpha)$ ，对 w, b 分别求偏导并令等于0

$$\text{由 } \nabla_w L(w, b, \alpha) = w - \sum_{i=1}^N \alpha_i y_i x_i = 0 \quad \rightarrow \quad w = \sum_{i=1}^N \alpha_i y_i x_i$$

$$\nabla_b L(w, b, \alpha) = \sum_{i=1}^N \alpha_i y_i = 0$$

$$\text{得: } L(w, b, \alpha) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i y_i \left(\sum_{j=1}^N \alpha_j y_j x_j \cdot x_i + b \right) + \sum_{i=1}^N \alpha_i$$

$$= -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$

$$\quad \quad \quad \uparrow$$

$$\min_{w,b} L(w, b, \alpha)$$



SVM的对偶算法

- 求 $\min_{w,b} L(w, b, \alpha)$ 对 α 的极大：

$$\max_{\alpha} \quad -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$\alpha_i \geq 0, i = 1, 2, \dots, N$$



$$\min_{\alpha} \quad \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i$$

$$s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$\alpha_i \geq 0, i = 1, 2, \dots, N$$



SVM的对偶算法

- 定理：设 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_l^*)$ 是对偶最优问题的解，则存在下标 j ，使得 $\alpha_j^* > 0$ ，并可按下式求得原始问题的解。

$$\text{证明：由 } \nabla_w L(w^*, b^*, \alpha^*) = w^* - \sum_{i=1}^N \alpha_i^* y_i x_i = 0$$

$$\nabla_b L(w^*, b^*, \alpha^*) = -\sum_{i=1}^N \alpha_i^* y_i = 0$$

$$\alpha_i^* (y_i (w^* \cdot x_i + b^*) - 1) = 0, i = 1, 2, \dots, N$$

$$y_i (w^* \cdot x_i + b^*) - 1 \geq 0, i = 1, 2, \dots, N$$

$$\alpha_i^* \geq 0, i = 1, 2, \dots, N$$

$$\text{得: } w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$$

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$



SVM的对偶算法

- 定理：设 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_l^*)^T$ 是对偶最优问题的解，则存在下标 j ，使得 $\alpha_j^* > 0$ ，并可按下式求得原始问题的解。
- 证明：由 $w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$ ，其中至少有一个 $\alpha_j^* > 0$

反证法：

假设： $\alpha^* = 0$ ，则 $w^* = 0$ ，

但这不是原始优化问题的解，产生矛盾

对此： j 有 $y_j (w^* \cdot x_j + b^*) - 1 = 0$

将式 $w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$ 代入并注意到 $\alpha_j^* > 0$

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$



SVM的对偶算法

- 由此定理可知，分离超平面可以写成：

$$\sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i) + b^* = 0$$

- 分类决策函数可以写成：

$$f(x) = \text{sign}(\sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i) + b^*)$$

- 这就是说，分类决策函数只依赖于输入 x 和训练样本输入的内积，上式称为线性可分支持向量机的对偶形式。



线性可分支持向量机器学习算法

- 输入：线性可分训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$
 $x_i \in \mathcal{X} = R^n, y_i \in \mathcal{Y} = \{+1, -1\}, i = 1, 2, \dots, N$

- 输出：最大间隔分离超平面和分类决策函数

- 1、构造并求解约束最优化问题

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i$$

$$s.t. \sum_{i=1}^N \alpha_i y_i = 0$$

$$\alpha_i \geq 0, i = 1, 2, \dots, N$$

- 求得最优解：

$$\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_l^*)^T$$



线性可分支持向量机器学习算法

- 2、计算 $w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$

并选择 α^* 的一个正分量 $\alpha_j^* > 0$ 计算

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

- 3、求得分离超平面 $w^* \cdot x + b^* = 0$

分类决策函数 $f(x) = \text{sign}(w^* \cdot x + b^*)$



支持向量

- 考虑原始优化问题和对偶优化问题，
- 将数据集中对应于 $\alpha_j^* > 0$ 的样本 (x_i, y_i) 的实例 $i \in R^n$
- 称为支持向量

- 支持向量一定在分割边界上，由KKT互补条件：

$$\alpha_i^* (y_i (w^* \cdot x_i + b^*) - 1) = 0, i = 1, 2, \dots, N$$

- 对应于 $\alpha_j^* > 0$ 的样本 x_i

$$y_i (w^* \cdot x_i + b^*) - 1 = 0$$

- 或

$$w^* \cdot x_i + b^* = \pm 1$$