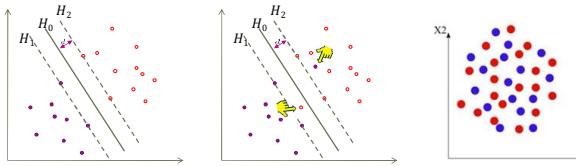




非线性可分问题

非线性可分：不能用一个超平面将数据进行分隔；

- ① 离群点导致的非线性可分：我们可以把非线性问题转化为“线性可分”问题，所以我们还是使用的“线性模型”来解决非线性可分问题
- ② 数据本质上是非线性可分：无法通过放松分隔条件来进行“变通”

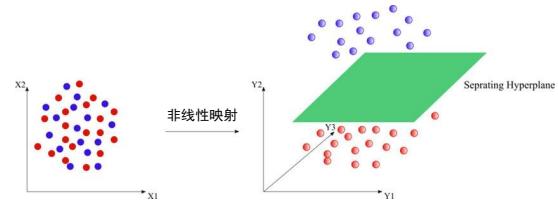


1



非线性可分问题

- 非线性问题往往不好求解
- 能不能转化为线性分类问题？



2



非线性可分问题

- 方法：进行一个非线性变换，将非线性问题变换为线性问题
- 通过解变换后的线性问题的方法求解原来的非线性问题。

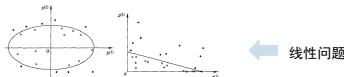
原空间：

$$\mathcal{X} \subset R^2, x = (x^{(1)}, x^{(2)})^T \in \mathcal{X}$$

新空间：

$$\mathcal{Z} \subset R^2, z = (z^{(1)}, z^{(2)})^T \in \mathcal{Z} \quad z = \phi(x) = ((x^{(1)})^2, (x^{(2)})^2)^T$$

$$w_1(x^{(1)})^2 + w_2(x^{(2)})^2 + b = 0 \quad \rightarrow \quad w_1 z^{(1)} + w_2 z^{(2)} + b = 0$$



3



核函数在支持向量机的应用

- 避免把低维度的数据转化到高维度的空间中，然后再去寻找线性分割平面
- 线性支持向量机对偶问题中，无论是目标函数还是决策函数都只涉及输入实例和实例之间的内积。

$$W(\alpha) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j x_i x_j - \sum_{i=1}^N \alpha_i$$

- 核函数：直接定义高维空间中的内积



核函数在支持向量机的应用

• 注意到：

线性支持向量机对偶问题中，无论是目标函数还是决策函数都只涉及输入实例和实例之间的内积。

$$W(\alpha) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j x_i x_j - \sum_{i=1}^N \alpha_i$$

• 目标函数中的内积 $x_i \cdot x_j$ 用核函数 $K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$

代替，目标函数：

$$W(\alpha) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \phi(x_i) \phi(x_j) - \sum_{i=1}^N \alpha_i$$

5



非线性支持向量机与核函数

- 核技巧的想法是：
- 在学习与预测中只定义核函数 $K(x, z)$ ，而不显式地定义映射函数

$$W(\alpha) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^N \alpha_i$$

- 直接计算 $K(x, z)$ 比较容易，
- 而通过 $\phi(x)$ 和 $\phi(z)$ 计算并不容易。

6



非线性支持向量机与核函数

• 核函数定义:

设 \mathcal{X} 是输入空间(欧氏空间 R^n 的子集或离散集合), 又设 \mathcal{H} 为特征空间(希尔伯特空间), 如果存在一个从 \mathcal{X} 到 \mathcal{H} 的映射 $\phi(x) : \mathcal{X} \rightarrow \mathcal{H}$

使得对所有 $x, z \in \mathcal{X}$

• 函数 $K(x, z)$ 满足条件 $K(x, z) = \phi(x) \cdot \phi(z)$

• 则称 $K(x, z)$ 为核函数 $\phi(x)$ 为映射函数,
式中 $\phi(x) \cdot \phi(z)$ 为 $\phi(x)$ 和 $\phi(z)$ 的内积



非线性支持向量机与核函数

• 例:

假设输入空间是 R^2 , 核函数是 $K(x, z) = (x \cdot z)^2$, 试找出其相关的特征空间 \mathcal{H} 和映射 $\phi(x) : R^2 \rightarrow \mathcal{H}$

解:

取特征空间 $\mathcal{H} = R^3$, 记 $x = (x^{(1)}, x^{(2)})^T, z = (z^{(1)}, z^{(2)})^T$

$(x \cdot z)^2 = (x^{(1)}z^{(1)} + x^{(2)}z^{(2)})^2 = (x^{(1)}z^{(1)})^2 + 2x^{(1)}z^{(1)}x^{(2)}z^{(2)} + (x^{(2)}z^{(2)})^2$

可以取: $\phi(x) = ((x^{(1)})^2, \sqrt{2}x^{(1)}x^{(2)}, (x^{(2)})^2)^T$

容易验证: $\phi(x) \cdot \phi(z) = (x \cdot z)^2 = K(x, z)$

7

8



非线性支持向量机与核函数

• 例:

假设输入空间是 R^2 , 核函数是 $K(x, z) = (x \cdot z)^2$, 试找出其相关的特征空间 \mathcal{H} 和映射 $\phi(x) : R^2 \rightarrow \mathcal{H}$

解:

同样:

$$\begin{aligned}\phi(x) &= \frac{1}{\sqrt{2}}((x^{(1)})^2 - (x^{(2)})^2, 2x^{(1)}x^{(2)}, (x^{(1)})^2 + (x^{(2)})^2)^T \\ \phi(x) &= ((x^{(1)})^2, x^{(1)}x^{(2)}, x^{(1)}x^{(2)}, (x^{(2)})^2)^T\end{aligned}$$

都满足条件。

9

10



正定核

• 问题:

• 已知映射函数 ϕ , 可以通过 $\phi(x)$ 和 $\phi(z)$ 的内积求得核函数 $K(x, z)$ 。

• 直接给定的函数 $K(x, z)$, 满足什么条件才能成为正定核函数?

• 正定核的充要条件

• 设 $K : \mathcal{X} \times \mathcal{X} \rightarrow R$, 是对称函数, 则 $K(x, z)$ 为正定核函数的充要条件是对任意 $x_i \in \mathcal{X}, i = 1, 2, \dots, m$, $K(x, z)$ 对应的Gram矩阵

$$K = [K(x_i, x_j)]_{m \times m}$$

是半正定的。



正定核

• 正定核的等价定义

• 设 $\mathcal{X} \subset R^n$, 是 $K(x, z)$ 是定义在 $\mathcal{X} \times \mathcal{X}$ 对称函数, 如果对任意的 $x_i \in \mathcal{X}, i = 1, 2, \dots, m$, $K(x, z)$ 对应的Gram矩阵

$$K = [K(x_i, x_j)]_{m \times m}$$

是半正定的, 则称 $K(x, z)$ 为正定核。

• 这一定义在构造核函数时很有用。但对于一个具体函数 $K(x, z)$ 来说, 检验它是否为正定核函数并不容易。

• 因为要求对任意有限输入集 $\{x_1, x_2, \dots, x_m\}$ 验证 K 对应的Gram矩阵是否为半正定的。

• 在实际问题中往往应用已有的核函数。

11

12



常用核函数

1、多项式核函数(Polynomial kernel function)

$$K(x, z) = (x \cdot z + 1)^p$$

• 对应的支持向量机为P次多项式分类器, 分类决策函数:

$$f(x) = sign(\sum_{i=1}^{N_s} \alpha_i^* y_i (x_i \cdot x + 1)^p + b^*)$$

2、高斯核函数(Gaussian Kernel Function)

$$K(x, z) = \exp(-\frac{\|x - z\|^2}{2\sigma^2})$$

• 决策函数:

$$f(x) = sign(\sum_{i=1}^{N_s} \alpha_i^* y_i \exp(-\frac{\|x - z\|^2}{2\sigma^2}) + b^*)$$



常用核函数

3、字符串核函数：

- 考虑一个有限字符表 Σ , 字符串 s 是从 Σ 中取出的有限字符的序列, 包括空字符串。 s 长度用 $|s|$ 表示, 元素记作 $s(1)s(2)...s(|s|)$ 。两串字符 s 和 t 的连接记作 st 。所有长度为 n 的字符串的集合记作 Σ^n , 所有字符串记作

$$\Sigma^* = \bigcup_{n=0}^{\infty} \Sigma^n$$

- 考虑 s 的子串 u , 给定一个指标序列

$$i = (i_1, i_2, \dots, i_{|u|}), 1 \leq i_1 < i_2 < \dots < i_{|u|} \leq |s|$$

- u 定义为 $u = s(i) = s(i_1)s(i_2)\dots s(i_{|u|})$, 长度记作 $l(i) = i_{|u|} - i_1 + 1$

如果 i 是连续的, 则 $l(i) = |u|$, 否则 $l(i) > |u|$



核函数的一些性质

核函数的和仍是核函数

$$K(x, y) = K_1(x, y) + K_2(x, y)$$

核函数的积, 仍是核函数

$$K(x, y) = K_1(x, y)K_2(x, y)$$

核函数的两端放缩, 仍是核函数

$$K(x, y) = f(x)K_1(x, y)f(y)$$

13

14



非线性支持向量机学习算法

- 输入: 线性不可分训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$

$$x_i \in \mathcal{X} = R^n, y_i \in \mathcal{Y} = \{-1, +1\}, i = 1, 2, \dots, N$$

- 输出: 分类决策函数

1、选取适当的核函数和参数 C , 构造最优化问题:

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) - \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & 0 \leq \alpha_i \leq C, i = 1, 2, \dots, N \end{aligned}$$

- 求得最优解: $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)^T$



非线性支持向量机学习算法

- 并选择 α^* , 适合条件 $0 < \alpha_j^* < C$, 计算

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i K(x_i, x_j)$$

- 构造决策函数

$$f(x) = \text{sign}\left(\sum_{i=1}^N \alpha_i^* y_i K(x, x_i) + b^*\right)$$

当 $K(x, z)$ 是正定核函数时, 优化问题是凸二次规划问题, 解是存在的。

15

16