

支持向量机




主要内容

SVM概述
最大分类间隔
支持向量机
二次凸优化
对偶学习算法



SVM

支持向量机(support vector machines. SVM)



Vladimir Vapnik



SVM

支持向量机(support vector machines. SVM)

- 二类分类模型 它的基本模型是定义在特征空间上的间隔最大的线性分类器，间隔最大使它有别于感知机；
- 支持向量机还包括核技巧，这使它成为实质上的非线性分类器。
- 支持向量机的学习策略就是间隔最大化，可形式化为一个求解凸二次规划(convex quadratic programming)的问题，也等价于正则化的合页损失函数的最小化问题。支持向量机的学习算法是求解凸二次规划的最优化算法。



SVM分类

支持向量机(support vector machines. SVM)

- 线性可分支持向量机(linear support vector machine in linearly separable case).
 - 硬间隔最大化(hard margin maximization);
- 线性支持向量机(linear support vector machine)
 - 训练数据近似线性可分时，通过软间隔最大化(soft margin maximization);
- 非线性支持向量机(non-linear support vector machine)
 - 当训练数据线性不可分时，通过使用核技巧(kernel trick)及软间隔最大化。



线性可分问题

假设特征空间上的训练数据集:

$$T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$$

$$x_i \in \mathcal{X} = \mathbb{R}^n, y_i \in \mathcal{Y} = \{+1, -1\}, i = 1, 2, \dots, N$$


- 正例和负例
- 学习的目标: 找到分类超平面,
- 回顾: 感知机模型, 学习得到的分离超平面
- 决策函数:

$$w^* \cdot x + b^* = 0$$

$$f(x) = \text{sign}(w^* \cdot x + b^*)$$



线性可分支持向量机与硬间隔最大化



超平面选择


经验风险最小

- 最小化训练集错分
- 解不唯一
- 容易受数据集缺陷影响

那是否可以从众多的分类超平面选择一个最优的？

需要新的标准

结构风险最小



超平面选择


经验风险最小

- 最小化训练集错分
- 解不唯一
- 容易受数据集缺陷影响

思考：
是否可以从众多的分类超平面选择一个最优的？

需要新的标准

- 结构风险最小
- 最大分类间隔



在某个分类超平面 H_0 的基础上再寻找两个超平面 H_1 和 H_2

$$H_0: w \cdot x + b = 0$$

$$H_1: w \cdot x + b = r$$

$$x_i \text{ 为正例: } w \cdot x + b \geq r$$


$$H_2: w \cdot x + b = -r$$

$$x_i \text{ 为负例: } w \cdot x + b \leq -r$$

等间距、平行



点到超平面的距离



$$|w \cdot x + b|$$

- 点到分离超平面的远近
- 表示分类预测的确信程度

$$y(w \cdot x + b)$$

- 分类的正确性
- 分类的确信度



函数间隔和几何间隔

• 函数间隔

• 样本点的函数间隔

$$\hat{\gamma}_i = y_i(w \cdot x_i + b)$$

• 训练数据集的函数间隔

$$\hat{\gamma} = \min_{i=1, \dots, N} \hat{\gamma}_i$$

• 表示分类预测的正确性和确信度

• 超平面不变的情况下

• 函数间隔随 w 和 b 的变化而成比例的改变

• 为了使间隔是确定的

• 对法向量 w 进行规范化

• $\|w\| = 1$

• 几何间隔

• 样本的几何间隔


$$\gamma_i = y_i \left(\frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right) \quad \gamma_i = \frac{\hat{\gamma}_i}{\|w\|}$$

• 数据集的几何间隔

$$\gamma = \min_{i=1, \dots, N} \gamma_i \quad \gamma = \frac{\hat{\gamma}}{\|w\|}$$



最大分类间隔



$$H_0: w \cdot x + b = 0$$

$$H_1: w \cdot x + b = r$$

$$H_2: w \cdot x + b = -r$$

$$d(H_1, H_0) = \frac{|(b-r) - b|}{\|w\|}$$

$$d = \frac{r}{\|w\|}$$

$$m = 2d = \frac{2r}{\|w\|}$$

$$\text{令 } r = 1$$

$$\text{间隔 } m = \frac{2}{\|w\|}$$



间隔最大化

最大间隔分类超平面

$$\max_{w,b} \frac{2}{\|w\|} \quad s.t. \quad y_i \left(\frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right) \geq 1, i = 1, 2, \dots, N$$

最大化 $\frac{2}{\|w\|}$ 等价于最小化 $\frac{1}{2} \|w\|^2$



线性可分支持向量机

线性可分支持向量机学习的最优化问题


$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad s.t. \quad y_i (w \cdot x_i + b) - 1 \geq 0, i = 1, 2, \dots, N$$

凸二次规划(convex quadratic programming)



凸集

- 一个点集(或区域), 如果连接其中任意两点 x_1, x_2 的线段都全部包含在该集合内, 就称该点集为凸集, 否则为非凸集。




凸函数

如果一个函数满足以下条件

- (1) 它的定义域 $\text{dom}(f)$ 是 \mathbb{R}^n 上的凸集, 并且
- (2) 对于所有的 $x_1, x_2 \in \text{dom}(f)$ 且 $\alpha \in (0,1)$

$$f(\alpha x_1 + (1-\alpha)x_2) \leq \alpha f(x_1) + (1-\alpha)f(x_2)$$

那么函数 f 为凸函数。




凸性条件

1. 根据一阶导数(函数的梯度)来判断函数的凸性设 $f(x)$ 为定义在凸集 R 上, 且具有连续的一阶导数的函数, 则 $f(x)$ 在 R 上为凸函数的充要条件是对凸集 R 内任意不同两点 x_1 与 x_2 , 不等式

$$f(x_2) \geq f(x_1) + (x_2 - x_1)^T \nabla f(x_1)$$

恒成立。



凸性条件

2. 根据二阶导数(Hessian矩阵)来判断函数的凸性设 $f(x)$ 为定义在凸集 R 上且具有连续二阶导数的函数, 则 $f(x)$ 在 R 上为凸函数的充要条件:

Hessian矩阵在 R 上处处半正定

$$H = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix} \succeq 0$$



凸优化问题

- 对于约束优化问题

$$\min f(x)$$

$$s.t. \quad g_j(x) \leq 0 \quad j = 1, 2, \dots, m$$

$$h_i(x) = 0, i = 1, 2, \dots, l$$

- 此问题为凸规划：
 - 若 $f(x)$ 与 $g_j(x)$ 都为连续可微的凸函数。
 - 若 $h_j(x)$ 为仿射变换。
- 凸规划的任何局部最优解就是**全局最优解**。
- 当目标函数为二次函数， g 函数为仿射函数时，为**凸二次规划问题**。



线性可分支持向量机学习算法

输入：线性可分训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$
 $x_i \in \mathcal{X} = R^n, y_i \in \mathcal{Y} = \{+1, -1\}, i = 1, 2, \dots, N$

输出：最大间隔分离超平面和分类决策函数

- 构造并求解约束最优化问题

$$\min_{w, b} \quad \frac{1}{2} \|w\|^2$$

$$s.t. \quad y_i(w \cdot x_i + b) - 1 \geq 0, i = 1, 2, \dots, N \quad \text{求得 } w^* \text{ 和 } b^*$$

- 得到分离超平面 $w^* \cdot x + b^* = 0$

$$\text{分类决策函数 } f(x) = \text{sign}(w^* \cdot x + b^*)$$




支持向量和Margins (边界)

在线性可分情况下，训练数据集的样本点中与**分离超平面**距离最近的样本点的实例称为支持向量(support vector)；

支持向量是使约束条件等号成立的点，即 $y_i(w \cdot x_i + b) - 1 = 0$

正例： $H_1: w \cdot x + b = 1$

负例： $H_2: w \cdot x + b = -1$



拉格朗日对偶

常规二次规划算法

- 约束数量多
 - 优化问题复杂
- 拉格朗日对偶算法
- 更容易求解
 - 方便使用核函数



拉格朗日对偶

原始问题：

$$\min_{w, b} \quad \frac{1}{2} \|w\|^2$$

$$s.t. \quad y_i(w \cdot x_i + b) - 1 \geq 0, i = 1, 2, \dots, N$$

在约束最优化问题中，常常利用拉格朗日对偶性(Lagrange duality)将原始问题转换为对偶问题，通过解对偶问题得到原始问题的解。



拉格朗日对偶


- 原始问题

设 $f(x), c(x), h(x)$ 是定义在 R^n 上的连续可微函数

$$\min_{x \in R^n} \quad f(x)$$

$$s.t. \quad c_i(x) \leq 0, i = 1, 2, \dots, k$$

$$h_j(x) = 0, j = 1, 2, \dots, l$$





拉格朗日对偶



1、原始问题

- 设 $f(x), c(x), h(x)$ 是定义在 R^n 上的连续可微函数

$$\min_{x \in R^n} f(x)$$

$$\text{s.t. } c_i(x) \leq 0, i = 1, 2, \dots, k$$

$$h_j(x) = 0, j = 1, 2, \dots, l$$



$$\nabla f + \alpha \nabla h_j = 0$$

$$L_j(x, \alpha_j) = f(x) + \alpha_j h_j(x)$$



拉格朗日对偶



1、原始问题

- 设 $f(x), c(x), h(x)$ 是定义在 R^n 上的连续可微函数

$$\min_{x \in R^n} f(x)$$

$$\text{s.t. } c_i(x) \leq 0, i = 1, 2, \dots, k$$

$$h_j(x) = 0, j = 1, 2, \dots, l$$



$$\nabla f + \alpha_i \nabla c_i = 0 \quad \alpha_i \geq 0$$

$$L_i(x, \alpha_i) = f(x) + \alpha_i c_i(x)$$



拉格朗日对偶

1、原始问题

- 设 $f(x), c(x), h(x)$ 是定义在 R^n 上的连续可微函数

$$\min_{x \in R^n} f(x)$$

$$\text{s.t. } c_i(x) \leq 0, i = 1, 2, \dots, k$$

$$h_j(x) = 0, j = 1, 2, \dots, l$$

- 引进拉格朗日函数 α_i, β_j 为乘子 $\alpha_j \geq 0$

$$L(x, \alpha, \beta) = f(x) + \sum_{i=1}^k \alpha_i c_i(x) + \sum_{j=1}^l \beta_j h_j(x)$$



拉格朗日对偶

$$L(x, \alpha, \beta) = f(x) + \sum_{i=1}^k \alpha_i c_i(x) + \sum_{j=1}^l \beta_j h_j(x)$$

- 考虑 x 的函数, P 为原始问题 $\theta_P(x) = \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta)$

- 假设给定某个 x , 如果 x 违反约束条件:

$$c_i(x) > 0 \quad h_j(x) \neq 0$$

$$\theta_P(x) = \max_{\alpha, \beta: \alpha_i \geq 0} [f(x) + \sum_{i=1}^k \alpha_i c_i(x) + \sum_{j=1}^l \beta_j h_j(x)] = +\infty$$



拉格朗日对偶

$$L(x, \alpha, \beta) = f(x) + \sum_{i=1}^k \alpha_i c_i(x) + \sum_{j=1}^l \beta_j h_j(x)$$

- 考虑优化问题 $\theta_P(x) = \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta)$

- 假设给定某个 x , 如果 x 符合约束条件:

$$h_j(w) = 0 \quad \nabla_x L = 0 \text{ 时取最优}$$

$$c_i(w) = 0 \quad \nabla_x L = 0 \text{ 时取最优 且 } \alpha > 0$$

$$c_i(w) < 0 \quad \nabla_x L = 0 \text{ 时取最优 且 } \alpha = 0$$

$$\rightarrow \alpha_i c_i(x) = 0, \alpha \geq 0$$

$$\theta_P(x) = \max_{\alpha, \beta: \alpha_i \geq 0} [f(x) + \sum_{i=1}^k \alpha_i c_i(x) + \sum_{j=1}^l \beta_j h_j(x)] = f(x)$$



拉格朗日对偶

$$\theta_P(x) = \begin{cases} f(x), & x \text{ 满足原始问题约束} \\ +\infty, & \text{其他} \end{cases}$$

- 考虑极小问题:

$$\min_x \theta_P(x) = \min_x \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta)$$

- 与原始最优化问题等价

$$p^* = \min_x \theta_P(x)$$



拉格朗日对偶

2、对偶问题

定义: $\theta_D(\alpha, \beta) = \min_x L(x, \alpha, \beta)$

$$\max_{\alpha, \beta: \alpha_i \geq 0} \theta_D(\alpha, \beta) = \max_{\alpha, \beta: \alpha_i \geq 0} \min_x L(x, \alpha, \beta)$$

则最大值问题:

- 称为广义拉格朗日函数的极大极小问题
- 表示为约束最优化问题: $\max_{\alpha, \beta} \theta_D(\alpha, \beta) = \max_{\alpha, \beta} \min_x L(x, \alpha, \beta)$
s.t. $\alpha_i \geq 0, i = 1, 2, \dots, k$
- 称为原始问题的对偶问题,
- 对偶问题的最优值 $d^* = \max_{\alpha, \beta: \alpha_i \geq 0} \theta_D(\alpha, \beta)$



原始问题和对偶问题的关系

定理:

若原始问题和对偶问题都有最优值, 则:

$$d^* = \max_{\alpha, \beta: \alpha_i \geq 0} \min_x L(x, \alpha, \beta) \leq \min_x \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta) = p^*$$

推论:

设 x^* , 和 α^* , β^* 分别是原始问题和对偶问题的可行解, 并且 $d^* = p^*$, 则 x^* , 和 α^* , β^* 分别是原始问题和对偶问题的最优解



KKT条件

定理: 对原始问题和对偶问题, 假设函数 $f(x)$ 和 $c_i(x)$ 是凸函数, $h_i(x)$ 是仿射函数, 并且不等式 $c_i(x)$ 是严格可行的, 则 x^* , 和 α^* , β^* 分别是原始问题和对偶问题的解的充分必要条件是 x^* , 和 α^* , β^* 满足 Karush-Kuhn-Tucker (KKT) 条件。

$$\nabla_x L(x^*, \alpha^*, \beta^*) = 0$$

$$\alpha_i^* c_i(x^*) = 0, i = 1, 2, \dots, k \quad \rightarrow \text{KKT互补条件}$$

$$c_i(x^*) \leq 0, i = 1, 2, \dots, k$$

$$\alpha_i^* \geq 0, i = 1, 2, \dots, k$$

$$h_j(x^*) = 0, j = 1, 2, \dots, l$$



SVM的对偶算法

对于线性可分支持向量机的优化问题, 原始问题:

$$\min_{w, b} \frac{1}{2} \|w\|^2$$

$$\text{s.t. } y_i(w \cdot x_i + b) - 1 \geq 0, i = 1, 2, \dots, N$$

应用拉格朗日对偶性, 通过求解对偶问题, 得到原始问题的解。

优点:

- 对偶问题往往容易解
- 引入核函数, 推广到非线性分类问题



SVM的对偶算法

定义拉格朗日函数

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i y_i (w \cdot x_i + b) + \sum_{i=1}^N \alpha_i$$

原问题: 极小极大, 对偶问题: 极大极小

$$\min_{w, b} \theta_P(w, b) = \min_{w, b} \max_{\alpha: \alpha_i \geq 0} L(w, b, \alpha)$$



$$\max_{\alpha: \alpha_i \geq 0} \min_{w, b} L(w, b, \alpha)$$



学习的对偶算法

先求 $L(w, b, \alpha)$ 对 w , b 的极小, 再求对 α 的极大

1、求: $\min_{w, b} L(w, b, \alpha)$, 对 w , b 分别求偏导并令等于0

$$\text{由 } \nabla_w L(w, b, \alpha) = w - \sum_{i=1}^N \alpha_i y_i x_i = 0 \quad \rightarrow \quad w = \sum_{i=1}^N \alpha_i y_i x_i$$

$$\nabla_b L(w, b, \alpha) = \sum_{i=1}^N \alpha_i y_i = 0 \quad \rightarrow \quad \sum_{i=1}^N \alpha_i y_i = 0$$

$$\text{得: } L(w, b, \alpha) = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i y_i \left(\left(\sum_{j=1}^N \alpha_j y_j x_j \right) \cdot x_i + b \right) + \sum_{i=1}^N \alpha_i$$

$$= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i$$

$$\quad \quad \quad \downarrow$$

$$\min_{w, b} L(w, b, \alpha)$$



SVM的对偶算法

求 $\min_{w,b} L(w, b, \alpha)$ 对 α 的极大:

$$\begin{aligned} \max_{\alpha} \quad & -\frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) + \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & \alpha_i \geq 0, \quad i = 1, 2, \dots, N \end{aligned}$$



$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & \alpha_i \geq 0, \quad i = 1, 2, \dots, N \end{aligned}$$



SVM的对偶算法

定理: 设 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_l^*)^T$ 是对偶最优问题的解, 则存在下标 j , 使得 $\alpha_j^* > 0$, 并可按下式求得原始问题的解。

证明: 由

$$\begin{aligned} w^* &= \sum_{i=1}^N \alpha_i^* y_i x_i \\ b^* &= y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j) \end{aligned}$$

$$\begin{aligned} \nabla_w L(w^*, b^*, \alpha^*) &= w^* - \sum_{i=1}^N \alpha_i^* y_i x_i = 0 \\ \nabla_b L(w^*, b^*, \alpha^*) &= -\sum_{i=1}^N \alpha_i^* y_i = 0 \\ \alpha_i^* (y_i (w^* \cdot x_i + b^*) - 1) &= 0, \quad i = 1, 2, \dots, N \\ y_i (w^* \cdot x_i + b^*) - 1 &\geq 0, \quad i = 1, 2, \dots, N \\ \alpha_i^* &\geq 0, \quad i = 1, 2, \dots, N \end{aligned}$$

得: $w^* = \sum_i \alpha_i^* y_i x_i$



SVM的对偶算法

定理: 设 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_l^*)^T$ 是对偶最优问题的解, 则存在下标 j , 使得 $\alpha_j^* > 0$, 并可按下式求得原始问题的解。

证明: 由 $w^* = \sum_i \alpha_i^* y_i x_i$, 其中至少有一个 $\alpha_j^* > 0$

反证法:

假设: $\alpha^* = 0$, 则 $w^* = 0$,

但这不是原始优化问题的解, 产生矛盾

对此: j 有 $y_j (w^* \cdot x_j + b^*) - 1 = 0$

$$\begin{aligned} \text{将式 } w^* &= \sum_{i=1}^N \alpha_i^* y_i x_i \quad \text{代入并注意到 } \mu_j^2 = 1 \\ b^* &= y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j) \end{aligned}$$



SVM的对偶算法

由此定理可知, 分离超平面可以写成:

$$\sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i) + b^* = 0$$

分类决策函数可以写成:

$$f(x) = \text{sign} \left(\sum_{i=1}^N \alpha_i^* y_i (x \cdot x_i) + b^* \right)$$

这就是说, 分类决策函数只依赖于输入 x 和训练样本输入的内积, 上式为线性可分支持向量机的对偶形式。



线性可分支持向量机器学习算法

输入: 线性可分训练数据集 $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$

$$x_i \in \mathcal{X} = R^n, y_i \in \mathcal{Y} = \{+1, -1\}, i = 1, 2, \dots, N$$

输出: 最大间隔分离超平面和分类决策函数

1、构造并求解约束最优化问题

$$\begin{aligned} \min_{\alpha} \quad & \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \\ \text{s.t.} \quad & \sum_{i=1}^N \alpha_i y_i = 0 \\ & \alpha_i \geq 0, \quad i = 1, 2, \dots, N \end{aligned}$$

求得最优解:

$$\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_l^*)^T$$



线性可分支持向量机器学习算法

2、计算 $w^* = \sum_{i=1}^N \alpha_i^* y_i x_i$

并选择 α^* 的一个正分量 $\alpha_j^* > 0$, 计算

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j)$$

3、求得分离超平面 $w^* \cdot x + b^* = 0$

分类决策函数 $f(x) = \text{sign}(w^* \cdot x + b^*)$



支持向量

• 考虑原始优化问题和对偶优化问题,

• 将数据集中对应于 $\alpha_j^* > 0$ 的样本 (x_i, y_i) 的实例 $x_i \in R^n$

• 称为支持向量

• 支持向量一定在分割边界上, 由KKT互补条件:

$$\alpha_i^* (y_i (w^* \cdot x_i + b^*) - 1) = 0, i = 1, 2, \dots, N$$

• 对应于 $\alpha_j^* > 0$ 的样本 x_i

$$y_i (w^* \cdot x_i + b^*) - 1 = 0$$

• 或

$$w^* \cdot x_i + b^* = \pm 1$$



结构化风险与正则化

$$L(w, b, a) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i y_i (w \cdot x_i + b) + \sum_{i=1}^N \alpha_i$$