

**第六章 逻辑斯蒂回归**

刘杰  
人工智能学院

Nankai University

**Generative V.S. Discriminative**

Task: to distinguish dog images from cat images.



**区分模型:** 尝试去学习区分类别。所以也许所有的训练数据中的狗都戴着项圈和项圈猫不是。如果这一个特征能很好地将类，模型是满意的。  
如果你问这样的模型，它对猫的了解，它能说的就是猫不戴项圈。而不能告诉你猫是什么样子。

2

**Generative V.S. Discriminative**


Task: to distinguish dog images from cat images.



**生成模型** 目标是了解狗的长相猫长什么样。  
“狗”模型能够“生成”狗。“猫”模型能够“生成”猫。  
对进行测试然后，系统会询问是猫模型还是狗模型更好能生成样本里的形象，则选择某个模型作为它的标签。

3

**Generative and Discriminative models**



4

**生成性模型**

Naïve Bayes

$\hat{c} = \arg\max_{c \in C} \widehat{P(d|c)} / \widehat{P(c)}$

A **generative model** like naive Bayes makes use of this **likelihood** term, which expresses how to generate the features of a document if we knew it was of class  $c$ .

5

**Naïve Bayes recap**

- Define  $p(x, y)$  via a **generative model**
- Prediction:  $\hat{y} = \arg \max_y p(x_i, y)$
- Learning:


$$\theta = \arg \max_{\theta} p(x, y; \theta)$$

$$p(x, y; \theta) = \prod_i p(x_i, y_i; \theta) = \prod_i p(x_i | y_i) p(y_i)$$

$$\phi_{y,j} = \frac{\sum_{i: Y_i=y} x_{ij}}{\sum_{i: Y_i=y} \sum_j x_{ij}}$$

$$\mu_y = \frac{\text{count}(Y = y)}{N}$$

This gives the maximum likelihood estimator (MLE; same as relative frequency estimator)



6

 **Discriminative Model**

By contrast a **discriminative model** in this text categorization scenario attempts to **directly** compute  $P(c|d)$ .

Perhaps it will learn to assign a high weight to document features that directly improve its ability to **discriminate** between possible classes, even if it couldn't generate an example of one of the classes.

7



 **The Perceptron**

The perceptron algorithm

- finds a separating hyperplane, if it exists;
- but it seems not a probabilistic model of  $P(y|x)$

In other words:

$$P(\mathbf{y}=1|\mathbf{x}) = 1 \text{ if } \mathbf{w} \cdot \phi(\mathbf{x}) \geq 0$$

$$P(\mathbf{y}=1|\mathbf{x}) = 0 \text{ if } \mathbf{w} \cdot \phi(\mathbf{x}) < 0$$



8

 **The Perceptron**

The perceptron algorithm

- finds a separating hyperplane, if it exists;
- but it seems not a probabilistic model of  $P(y|x)$


我们希望  $z$  可以是一个合法的概率

$$z = \mathbf{w} \cdot \phi(\mathbf{x}) + b$$

然而  $z$  不在0和1之间, 甚至可以为负  
 $z$  的取值  $(-\infty, \infty)$

In other words:

$$P(\mathbf{y}=1|\mathbf{x}) = 1 \text{ if } \mathbf{w} \cdot \phi(\mathbf{x}) \geq 0$$

$$P(\mathbf{y}=1|\mathbf{x}) = 0 \text{ if } \mathbf{w} \cdot \phi(\mathbf{x}) < 0$$


通过 sign()强行对  $p(y|x)$  进行赋值  
最好能有一个平滑的概率函数进行建模


9

 **Perceptron & Probabilities**

**Sigmoid 函数**

$$y = \sigma(z) = \frac{1}{1 + e^{-z}}$$

优点:  
值域  $[0,1]$ , 满足概率取值要求  
可微可导, 对学习算法友好



10

 **Perceptron & Probabilities**

If we want a probability  $P(y|x)$

$P(\mathbf{y}=1|\mathbf{x}) = \frac{e^{\mathbf{w} \cdot \phi(\mathbf{x})}}{1+e^{\mathbf{w} \cdot \phi(\mathbf{x})}}$

- "Softer" function than in perceptron
- Can account for uncertainty
- Differentiable

11

 **逻辑斯蒂分布**

Logistic distribution  
设  $X$  是连续随机变量,  $X$  服从 Logistic distribution,

- 分布函数:  $F(x) = P(X \leq x) = \frac{1}{1 + e^{-\frac{x-\mu}{\gamma}}}$
- 密度函数:  $f(x) = F'(x) = \frac{e^{-\frac{x-\mu}{\gamma}}}{\gamma(1 + e^{-\frac{x-\mu}{\gamma}})^2}$

•  $\mu$  为位置参数,  $\gamma$  大于 0 为形状参数,  
( $\mu, 1/2$ ) 中心对称

$$F(-x + \mu) - \frac{1}{2} = -F(x - \mu) + \frac{1}{2}$$


12

 **二项逻辑斯蒂回归**

Binomial logistic regression model

- 由条件概率 $P(Y|X)$ 表示的分类模型
- 形式为参数化的logistic distribution
- X取实数, Y取值1,0

$$P(Y = 1|x) = \frac{e^{w \cdot x + b}}{1 + e^{w \cdot x + b}}$$

$$P(Y = 0|x) = \frac{1}{1 + e^{w \cdot x + b}}$$

$w = (w^{(1)}, w^{(2)}, \dots, w^{(n)}, b)^T$ 
 $x = (x^{(1)}, x^{(2)}, \dots, x^{(n)}, 1)^T$

 **二项逻辑斯蒂回归**

事件的几率odds: 事件发生与事件不发生的概率之比为

$$\frac{p}{1-p}$$

称为事件的发生比(the odds of experiencing an event),

对数几率:

$$\text{logit}(p) = \log \frac{p}{1-p}$$

对数逻辑斯蒂回归:

$$\log \frac{P(Y = 1|x)}{1 - P(Y = 1|x)} = w \cdot x$$



## 似然函数

• logistic分类器是由一组权值系数组成的，最关键的问题就是如何获取这组权值，通过极大似然函数估计获得，并且 $\hat{Y} = f(x; w)$

• **似然函数**是统计模型中参数的函数。给定输出 $x$ 时，关于参数 $\theta$ 的似然函数 $L(\theta|x)$ （在数值上）等于给定参数 $\theta$ 后变量 $X$ 的概率： $L(\theta|x) = P(X=x|\theta)$

• 似然函数的重要性不是它的取值，而是当参数变化时概率密度函数到底是变大还是变小。

• 极大似然函数：似然函数取得最大值表示相应的参数能够使得统计模型最为合理

15



## 似然函数

• 那么对于上述 $N$ 个观测事件，设

$$P(Y = 1|x) = \pi(x), P(Y = 0|x) = 1 - \pi(x)$$

• 其联合概率密度函数，即似然函数为：

$$\prod_{i=1}^N [\pi(x_i)]^{y_i} [1 - \pi(x_i)]^{1-y_i}$$

• 目标：求出使这一似然函数的值最大的参数估， $w_1, w_2, \dots, w_n$ ，使得 $L(w)$ 取得最大值。

• 对 $L(w)$ 取对数：

16



## 模型参数估计

对数似然函数

$$L(w) = \sum_{i=1}^N [y_i \log \pi(x_i) + (1 - y_i) \log(1 - \pi(x_i))]$$

$$= \sum_{i=1}^N [y_i \log \frac{\pi(x_i)}{1 - \pi(x_i)} + \log(1 - \pi(x_i))]$$

$$= \sum_{i=1}^N [y_i(w \cdot x_i) - \log(1 + e^{w \cdot x_i})]$$

对 $L(w)$ 求极大值，得到 $w$ 的估计值。

通常采用梯度下降法及拟牛顿法，学到的模型：

$$P(Y = 1|x) = \frac{e^{w \cdot x}}{1 + e^{w \cdot x}} \quad P(Y = 0|x) = \frac{1}{1 + e^{w \cdot x}}$$

17



## 多项logistic回归

设 $Y$ 的取值集合为

$$\{1, 2, \dots, K\}$$

多项logistic回归模型

$$P(Y = k|x) = \frac{e^{w_k \cdot x}}{1 + \sum_{k=1}^{K-1} e^{w_k \cdot x}}, k = 1, 2, \dots, K-1$$

$$P(Y = K|x) = \frac{1}{1 + \sum_{k=1}^{K-1} e^{w_k \cdot x}}$$

18



## 最大熵模型

• 最大熵模型(Maximum Entropy Model)由最大熵原理推导实现。

### • 最大熵原理:

• 学习概率模型时, 在所有可能的概率模型(分布)中, 熵最大的模型是最好的模型, 表示为在满足约束条件的模型集合中选取熵最大的模型。

• 假设离散随机变量X的概率分布是P(X),

$$\text{熵: } H(P) = - \sum_x P(x) \log P(x)$$

• 且:  $0 \leq H(P) \leq \log |X|$

•  $|X|$ 是X的取值个数, X均匀分布时右边等号成立。

19



## 例子:

• 假设随机变量X有5个取值(A,B,C,D,E),估计各个值的概率。

• 解: 满足  $P(A) + P(B) + P(C) + P(D) + P(E) = 1$

• 等概率估计:  $P(A) = P(B) = P(C) = P(D) = P(E) = \frac{1}{5}$

• 加入一些先验:  $P(A) + P(B) = \frac{3}{10}$

$$P(A) + P(B) + P(C) + P(D) + P(E) = 1$$

• 于是:  $P(A) = P(B) = \frac{3}{20}$

$$P(C) = P(D) = P(E) = \frac{7}{30}$$

20



## 例子:

• 假设随机变量X有5个取值(A,B,C,D,E),估计各个值的概率。

• 解: 满足  $P(A) + P(B) + P(C) + P(D) + P(E) = 1$

• 等概率估计:  $P(A) = P(B) = P(C) = P(D) = P(E) = \frac{1}{5}$

• 加入一些先验:  $P(A) + P(B) = \frac{3}{10}$

$$P(A) + P(B) + P(C) + P(D) + P(E) = 1$$

• 于是:  $P(A) = P(B) = \frac{3}{20}$  再加入约束:  $P(A) + P(C) = \frac{1}{2}$

$$P(C) = P(D) = P(E) = \frac{7}{30}$$

$$P(A) + P(B) = \frac{3}{10}$$

$$P(A) + P(B) + P(C) + P(D) + P(E) = 1$$

21



## 最大熵模型

• X和Y分别是输入和输出的集合, 这个模型表示的是对于给定的输入X, 以条件概率P(Y|X)输出Y。

• 给定数据集:

$$T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$$

• 联合分布P(Y|X)的经验分布, 边缘分布P(X)的经验分布:

$$\tilde{P}(X, Y) \rightarrow \tilde{P}(X = x, Y = y) = \frac{V(X = x, Y = y)}{N}$$

$$\tilde{P}(X) \rightarrow \tilde{P}(X = x) = \frac{V(X = x)}{N}$$

• 特征函数:  $f(x, y) = \begin{cases} 1, & x \text{与} y \text{满足某一事实} \\ 0, & \text{否则} \end{cases}$

22



## 最大熵模型

• 特征函数f(x,y)关于经验分布 $\tilde{P}(X, Y)$ 的期望值:

$$E_{\tilde{P}}(f) = \sum_{x, y} \tilde{P}(x, y) f(x, y)$$

• 特征函数f(x,y)关于模型P(Y|X)与经验分布 $\tilde{P}(X)$ 的期望值:

$$E_P(f) = \sum_x \tilde{P}(x) P(y|x) f(x, y)$$

• 如果模型能够获取训练数据中的信息, 那么就可以假设这两个期望值相等, 即

$$E_P(f) = E_{\tilde{P}}(f) \rightarrow \sum_{x, y} \tilde{P}(x) P(y|x) f(x, y) = \sum_{x, y} \tilde{P}(x, y) f(x, y)$$

• 假设有n个特征函数:

$$f_i(x, y), i = 1, 2, \dots, n$$

23



## 最大熵模型

• 定义:

• 假设满足所有约束条件的模型集合为:

$$\mathcal{C} \equiv \{P \in \mathcal{P} | E_P(f_i) = E_{\tilde{P}}(f_i), i = 1, 2, \dots, n\}$$

• 定义在条件概率分布P(Y|X)上的条件熵:

$$H(P) = - \sum_{x, y} \tilde{P}(x) P(y|x) \log P(y|x)$$

• 则模型集合C中条件熵H(P)最大的模型称为最大熵模型

24



## 最大熵模型的学习

• 最大熵模型的学习可以形式化为约束最优化问题。

• 对于给定的数据集以及特征函数:  $f_i(x, y)$

• 最大熵模型的学习等价于约束最优化问题:

$$\begin{aligned} \max_{\mathcal{P} \in \mathcal{C}} H(\mathcal{P}) &= - \sum_{x,y} \tilde{P}(x) P(y|x) \log P(y|x) & \min_{\mathcal{P} \in \mathcal{C}} -H(\mathcal{P}) &= \sum_{x,y} \tilde{P}(x) P(y|x) \log P(y|x) \\ \text{s.t. } E_{\mathcal{P}}(f_i) &= E_{\tilde{\mathcal{P}}}(f_i), i = 1, 2, \dots, n & \text{s.t. } E_{\mathcal{P}}(f_i) - E_{\tilde{\mathcal{P}}}(f_i) &= 0, i = 1, 2, \dots, n \\ \sum_y P(y|x) &= 1 & \sum_y \tilde{P}(y|x) - 1 &= 0 \end{aligned}$$

25



## 最大熵模型的学习

• 这里, 将约束最优化的原始问题转换为无约束最优化的对偶问题, 通过求解对偶问题求解原始问题。

• 引进拉格朗日乘子, 定义拉格朗日函数:

$$\begin{aligned} L(\mathcal{P}, w) &= -H(\mathcal{P}) + w_0(1 - \sum_y P(y|x)) + \sum_{i=1}^n w_i(E_{\tilde{\mathcal{P}}}(f_i) - E_{\mathcal{P}}(f_i)) \\ &= \sum_{x,y} \tilde{P}(x) P(y|x) \log P(y|x) + w_0(1 - \sum_y P(y|x)) \\ &\quad + \sum_{i=1}^n w_i(\sum_{x,y} \tilde{P}(x, y) f_i(x, y) - \sum_{x,y} \tilde{P}(x) P(y|x) f_i(x, y)) \end{aligned}$$

• 最优化原始问题可表示为:

$$\min_{\mathcal{P} \in \mathcal{C}} \max_w L(\mathcal{P}, w)$$

26



## 最大熵模型的学习

• 最优化原始问题到对偶问题:

$$\min_{\mathcal{P} \in \mathcal{C}} \max_w L(\mathcal{P}, w) \xrightarrow{\text{对偶问题}} \max_w \min_{\mathcal{P} \in \mathcal{C}} L(\mathcal{P}, w)$$

•  $L(\mathcal{P}, w)$  是  $\mathcal{P}$  的凸函数, 解的等价性 (证明部分在 SVM 部分介绍)

• 先求极小化问题:  $\min_{\mathcal{P} \in \mathcal{C}} L(\mathcal{P}, w)$  是  $w$  的函数,

$$\Psi(w) = \min_{\mathcal{P} \in \mathcal{C}} L(\mathcal{P}, w) = L(P_w, w)$$

$$P_w = \arg \min_{\mathcal{P} \in \mathcal{C}} L(\mathcal{P}, w) = P_w(y|x)$$

27



## 最大熵模型的学习

• 求  $L(P, w)$  对  $P(y|x)$  的偏导数:

$$\begin{aligned} \frac{\partial L(P, w)}{\partial P(y|x)} &= \sum_{x,y} \tilde{P}(x)(\log P(y|x) + 1) - \sum_y w_0 - \sum_{x,y} (\tilde{P}(x) \sum_{i=1}^n w_i f_i(x, y)) \\ &= \sum_{x,y} \tilde{P}(x)(\log P(y|x) + 1 - w_0 - \sum_{i=1}^n w_i f_i(x, y)) \end{aligned}$$

• 令偏导数为零, 得:

$$P(y|x) = \exp(\sum_{i=1}^n w_i f_i(x, y) + w_0 - 1) = \frac{\exp(\sum_{i=1}^n w_i f_i(x, y))}{\exp(1 - w_0)}$$

28



## 最大熵模型的学习

• 由:  $\sum_y P(y|x) = 1$

$$\text{得: } P_w(y|x) = \frac{1}{Z_w(x)} \exp(\sum_{i=1}^n w_i f_i(x, y)) \quad (6.22)$$

$$\text{规范化因子: } Z_w(x) = \sum_y \exp(\sum_{i=1}^n w_i f_i(x, y)) \quad (6.23)$$

• 模型  $P_w = P_w(y|x)$  就是**最大熵模型**

• 求解对偶问题外部的极大化问题:

$$\max_w \Psi(w) \quad w^* = \arg \max_w \Psi(w) \quad P^* = P_{w^*} = P_{w^*}(y|x)$$

29



## 例子:

原例子中的最大熵模型:

$$\min -H(\mathcal{P}) = \sum_{i=1}^5 P(y_i) \log P(y_i)$$

$$\text{s.t. } P(y_1) + P(y_2) = \tilde{P}(y_1) + \tilde{P}(y_2) = \frac{3}{10}$$

$$\sum_{i=1}^5 P(y_i) = \sum_{i=1}^5 \tilde{P}(y_i) = 1$$

$$L(\mathcal{P}, w) = \sum_{i=1}^5 P(y_i) \log P(y_i) + w_1(P(y_1) + P(y_2) - \frac{3}{10}) + w_0(\sum_{i=1}^5 P(y_i) - 1)$$

$$\max_w \min_{\mathcal{P}} L(\mathcal{P}, w)$$

30



## 例子：

$$\begin{aligned}\frac{\partial L(P, w)}{\partial P(y_1)} &= 1 + \log P(y_1) + w_1 + w_0 \\ \frac{\partial L(P, w)}{\partial P(y_2)} &= 1 + \log P(y_2) + w_1 + w_0 \\ \frac{\partial L(P, w)}{\partial P(y_3)} &= 1 + \log P(y_3) + w_0 \\ \frac{\partial L(P, w)}{\partial P(y_4)} &= 1 + \log P(y_4) + w_0 \\ \frac{\partial L(P, w)}{\partial P(y_5)} &= 1 + \log P(y_5) + w_0\end{aligned}$$

解得：  
 $P(y_1) = P(y_2) = e^{-w_1-w_0-1}$   
 $P(y_3) = P(y_4) = P(y_5) = e^{-w_0-1}$

31



## 例子：

$$\min_P L(P, w) = L(P_w, w) = -2e^{-w_1-w_0-1} - 3e^{-w_0-1} - \frac{3}{10}w_1 - w_0$$

得：

$$\max_w L(P_w, w) = -2e^{-w_1-w_0-1} - 3e^{-w_0-1} - \frac{3}{10}w_1 - w_0$$

对  $w_i$  求偏导并令为0：

$$\begin{aligned}e^{-w_1-w_0-1} &= \frac{3}{20} \\ e^{-w_0-1} &= \frac{7}{20}\end{aligned} \quad \longrightarrow \quad \begin{aligned}P(y_1) &= P(y_2) = \frac{3}{20} \\ P(y_3) &= P(y_4) = P(y_5) = \frac{7}{20}\end{aligned}$$

32



## 极大似然估计

最大熵模型就是(6.22),(6.23)表示的条件概率分布，

证明：对偶函数的极大化等价于最大熵模型的极大似然估计。

已知训练数据的经验概率分布  $\tilde{P}(X, Y)$  条件概率分布  $P(Y|X)$  的对数似然函数表示为：

$$\begin{aligned}L_{\tilde{P}}(P_w) &= \log \prod_{x,y} P(y|x)^{\tilde{P}(x,y)} = \sum_{x,y} \tilde{P}(x,y) \log P(y|x) \\ &= \sum_{x,y} \tilde{P}(x,y) \sum_{i=1}^n w_i f_i(x,y) - \sum_{x,y} \tilde{P}(x,y) \log Z_w(x) \\ &= \sum_{x,y} \tilde{P}(x,y) \sum_{i=1}^n w_i f_i(x,y) - \sum_x \tilde{P}(x) \log Z_w(x)\end{aligned}$$

33



## 极大似然估计

$$\begin{aligned}\text{而: } \Psi(w) &= \sum_{x,y} \tilde{P}(x,y) P_w(y|x) \log P_w(y|x) \\ &\quad + \sum_{i=1}^n w_i \left( \sum_{x,y} \tilde{P}(x,y) f_i(x,y) - \sum_{x,y} \tilde{P}(x) P_w(y|x) f_i(x,y) \right) \\ &= \sum_{x,y} \tilde{P}(x,y) \sum_{i=1}^n w_i f_i(x,y) + \sum_{x,y} \tilde{P}(x) P_w(y|x) (\log P_w(y|x) - \sum_{i=1}^n w_i f_i(x,y)) \\ &= \sum_{x,y} \tilde{P}(x,y) \sum_{i=1}^n w_i f_i(x,y) - \sum_{x,y} \tilde{P}(x) P_w(y|x) \log Z_w(x) \\ &= \sum_{x,y} \tilde{P}(x,y) \sum_{i=1}^n w_i f_i(x,y) - \sum_{x,y} \tilde{P}(x) \log Z_w(x)\end{aligned}$$

34



## 极大似然估计

最大熵模型与逻辑斯谛回归模型有类似的形式，它们又称  
为对数线性模型(log linear model)。

模型学习就是在给定的训练数据条件下对模型进行极大似  
然估计或正则化的极大似然估计。

35



## 模型学习的最优化算法

逻辑斯谛回归模型、最大熵模型学习归结为以似然函数为目标函数的最优化问  
题，通常通过迭代算法求解，它是光滑的凸函数，因此多种最优化的方法都适  
用。

常用的方法有：

- 改进的迭代尺度法
- 梯度下降法
- 牛顿法
- 拟牛顿法

36